

Ferramentas Utilizadas nos artigos de Isaac Caraça

Ferramentas necessárias:

1. Tesseract OCR

Função: responsável por reconhecer e extrair o texto das imagens geradas a partir das páginas dos PDFs digitalizados.

link: [<https://github.com/UB-Mannheim/tesseract/wiki>]

Após acessar o link na pagina procure por:

Link: [tesseract-ocr-w64-setup-5.5.0.20241111.exe]

Execute o instalador.

Selecione Add Tesseract to system path para que o executável seja reconhecido no terminal ou via PHP.

Selecione o idioma Portuguese (por.traineddata) durante a instalação.

Confirme a instalação:

Abra o Prompt de Comando (CMD) e digite:

```
tesseract -v
```

Você deve ver a versão instalada do Tesseract.

Caso de erro:

```
'tesseract.exe' não é reconhecido como um comando interno ou externo
```

Isso significa que o PHP não está encontrando o executável, mesmo que ele esteja instalado corretamente.

O motivo mais comum: caminho para o executável não está nas variáveis de ambiente do Windows.

Para resolver isso:

Pressione Win + R, digite sysdm.cpl e pressione Enter.

Na janela Propriedades do Sistema, vá para Avançado → Variáveis de Ambiente.

Editar o PATH

Em Variáveis do sistema, encontre a variável Path e clique em Editar.

Clique em Novo e adicione o caminho das pastas que contêm os executáveis:

Exemplo:

```
C:\Program Files\Tesseract-OCR
```

Depois teste no CMD:

```
tesseract -v
```

2. Poppler

Função: converte os arquivos PDF em imagens (uma imagem por página), permitindo que o Tesseract realize a leitura visual.

Link: [<https://github.com/oschwartz10612/poppler-windows/releases/>]

Após acessar o link procure por:

[Release-25.07.0-0.zip]

Faça a descompactação e depois siga o passo a passo de instalação.

Confirme a instalação:

Abra o Prompt de Comando (CMD) e digite:

```
pdftoppm -h
```

Você deve ver a versão instalada do Poppler.

Caso de erro:

```
'pdftoppm.exe' não é reconhecido como um comando interno ou externo
```

Esses erros indicam que o PHP não consegue encontrar o executável.

Para resolver isso:

Corrigindo via variáveis de ambiente

Pressione Win + R, digite sysdm.cpl e pressione Enter.

Vá em Avançado → Variáveis de Ambiente.

Em Variáveis do sistema, localize Path e clique em Editar.

Adicione o caminho da pasta bin do Poppler, por exemplo:

```
C:\Poppler\Release-23.10.0-0\poppler-23.10.0\Library\bin
```

Depois teste no CMD:

```
pdftoppm -h
```

Teste manual na Prática:

com o pdf na máquina, para testar o poppler, no CMD execute:

```
"C:\Poppler\Release-23.10.0-0\poppler-23.10.0\Library\bin\pdftoppm.exe" -png -r 150 exemplo.pdf saida
```

Isso irá gerar imagens saida-1.png, saida-2.png, etc., a partir do PDF exemplo.pdf.

Após fazer esse procedimento, use o Tesseract para gerar o .txt. No CMD execute:

```
tesseract saida-1.png saida-1 -l por
```

Isso criará um arquivo saida-1.txt contendo o texto reconhecido da imagem saida-1.png.

Com isso vc pode usar esse texto para sua aplicação dependendo das necessidades.

3. LanguageTool

Pré-requisitos (Windows)

Java (JRE/JDK) instalado — o LanguageTool precisa do Java.

Teste no CMD:

```
java -version
```

Se der erro, baixe e instale o JRE/JDK da Oracle ou OpenJDK e depois abra um novo terminal.

(Opcional) Se preferir rodar o servidor do LanguageTool manualmente, baixe o LanguageTool Standalone (arquivo .zip com languagetool-server.jar) do site oficial e extraia.

2. Instalação do pacote Python

Abra o terminal (CMD/PowerShell) e instale:

```
pip install language-tool-python
```

Observação: o nome do pacote no pip é language-tool-python (mas no código você importa language_tool_python).

3. Teste mínimo — checar e corrigir uma string

Salve o arquivo exemplo_languagetool.py com o conteúdo abaixo e execute:

exemplo_languagetool.py

```
import language_tool_python
```

Cria a instância do LanguageTool para Português do Brasil

```
tool = language_tool_python.LanguageTool('pt-BR')
```

```
texto = "Este é um texto com alguns erros de ortografia e concordancia."
```

Busca os "matches" (sugestões/erros)

```
matches = tool.check(texto)
```

Mostra os matches

```
for m in matches:  
    print(f"{m.ruleId}: {m.message} ->  
    '{texto[m.offset:m.offset+m.errorLength]}')  
    print("Sugestões:", m.replacements)  
  
    print("---")
```

Aplica as correções automaticamente (retorna o texto corrigido)

```
texto_corrigido = language_tool_python.utils.correct(texto, matches)  
print("\nOriginal:", texto)  
  
print("Corrigido:", texto_corrigido)
```

Fechar o tool (boas práticas)

```
tool.close()
```

Explicação:

- `LanguageTool('pt-BR')` cria cliente que usa o servidor interno do pacote (faz download do jar automaticamente se necessário).
- `check(texto)` retorna lista de matches.
- `utils.correct(text, matches)` aplica substituições sugeridas automaticamente.

4. Dicionário (Português)

Função: o dicionário serve como base para validar palavras reconhecidas, filtrando erros do OCR e ajudando na correção automática.

Link oficial (dicionário em texto):

```
https://www.ime.usp.br/~pf/dicios/br-utf8.txt
```

Como baixar:

Acesse o link acima.

Clique com o botão direito na página e escolha “Salvar como...”.

Salve o arquivo como, por exemplo:

```
C:\xampp\htdocs\leis_externo\br-utf8.txt
```

Observação:

Você pode utilizar qualquer outro dicionário em formato `.txt`, desde que contenha uma palavra por linha e esteja codificado em UTF-8, para garantir compatibilidade com a aplicação.

5. Instalação de bibliotecas Python

Função: este passo instala todas as dependências necessárias para o funcionamento completo do sistema — desde a extração de texto (OCR) até a correção ortográfica e integração com banco de dados.

Passos:

Abra o Prompt de Comando (CMD) ou o terminal do seu ambiente virtual Python.

Execute o seguinte comando:

```
pip install psycpg2-binary opencv-python pymupdf numpy pytesseract  
pillow language-tool-python unidecode requests
```

psycpg2-binary:

usada para se conectar e manipular bancos de dados PostgreSQL diretamente a partir do Python, permitindo executar comandos SQL, inserir e consultar dados.

opencv-python (cv2):

biblioteca voltada ao processamento e análise de imagens, útil para preparar os arquivos antes do OCR (melhorar contraste, ajustar brilho, remover ruídos, etc).

pymupdf (fitz):

responsável por abrir, ler e extrair o conteúdo de arquivos PDF, inclusive suas páginas e imagens, que podem ser passadas ao Tesseract.

numpy:

usada para operações matemáticas e manipulação de arrays de pixels nas imagens, auxiliando no desempenho das etapas de pré-processamento.

pytesseract:

é o módulo que conecta o Python ao Tesseract OCR, permitindo enviar imagens para reconhecimento de texto e obter o resultado diretamente como string.

pillow (PIL):

biblioteca de manipulação de imagens, utilizada para abrir, salvar, converter formatos e tratar arquivos antes do OCR.

language-tool-python:

módulo responsável pela verificação gramatical e ortográfica, aplicando as regras do LanguageTool diretamente dentro do seu código Python.

unidecode:

remove acentuação e caracteres especiais de textos, padronizando o conteúdo antes da correção ou comparação.

requests:

permite fazer requisições HTTP, como baixar dicionários externos ou enviar dados para APIs.

Observação:

O pacote psychopg2-binary é usado no lugar de psychopg2 por ser mais simples de instalar (dispensa compilação local).

Verifique se a instalação ocorreu corretamente executando no terminal Python:

```
import sys, os, subprocess, tempfile, glob, requests, re, time
import psychopg2, psychopg2.extras
import cv2
import fitz
import numpy as np
import pytesseract
from PIL import Image
import re
import unicodedata

import language_tool_python
from difflib import get_close_matches
from unidecode import unidecode
from concurrent.futures import ThreadPoolExecutor, as_completed

print("✅ Todas as bibliotecas foram importadas com sucesso.")
```

Se o script acima não gerar nenhum erro, significa que o ambiente está configurado corretamente.